Estadística II - Taller 07 Semestre: 2023-02

Monitor: Matheo Muñoz Betancur

1. Responda las siguientes preguntas teóricas:

- a) Suponga que se realiza escalamiento de longitud unitaria en las predictoras pero no en la variable respuesta, ¿qué unidades tienen los coeficientes de la regresión una vez esta es ajustada?
- b) ¿Por qué hay problemas de multicolinealidad cuando se tienen más covariables que observaciones en los datos?
- c) Si la traza de la matriz $\mathbf{X}'\mathbf{X}$ es muy grande, ¿mayor es la distancia entre el vector de parámetros estimados y el verdadero vector de parámetros?
- d) Si la correlación entre las variables X_j y X_k es pequeña, ¿se puede descartar la presencia de multicolinealidad?
- e) ¿Hay problemas de multicolinealidad en un modelo de 7 predictoras en el cual para β_3 , $R_3 = \sqrt{\frac{4}{5}}$? Recuerde que R_j^2 es el coeficiente de determinación muestral obtenido de una regresión de X_j (como respuesta) en función de las otras variables predictoras consideradas en el modelo (actuando como predictoras de X_j).
- 2. Se genera un modelo de regresión lineal múltiple $y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \varepsilon_i$, $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$ con vector de parámetros $\beta' = (\beta_0 = -3, \beta_1 = 2, \beta_2 = -4, \sigma^2 = 4)$. Cree dos bases de datos usando las siguientes instrucciones.

```
gen_dat <- function(n) {
    x1 <- runif(n=n, min=0, max=10)
    x2 <- x1 * 2 + rnorm(n=n, sd=0.01) # x2 es el doble de x1 + ruido
    y <- rnorm(n=n, mean= - 3 + 2 * x1 - 4 * x2, sd=2)
    data.frame(y, x1, x2)
}
set.seed(12345)
datos <- gen_dat(n=40)
datos1 <- datos[1:20, ]
datos2 <- datos[21:40, ]</pre>
```

Luego de ajustar el modelo, obtenga los coeficientes estimados y comparelos con los reales, ¿qué sucede? Además, calcule los VIF y haga análisis del espectro de la matriz X'X.

3. Considere la base de datos earthquake del paquete MPV, seleccione el mejor modelo usando como criterios el MSE_p o equivalentemente R^2_{adj} y el C_p de Mallows al emplear el método de selección de todas las regresiones posibles.